
DreemGO

Inteligencia de rutas turísticas para el Perú real

Semana 6 · Análisis Exploratorio de Datos (EDA) y Motor Predictivo

De los datos crudos a la señal predictiva: 3 fuentes integradas, 12 visualizaciones y 6 hallazgos accionables

6,160

fichas MINCETUR

2,880

meses de clima

500

eventos locales

10

años de historia

DS3022 · Desarrollo de Producto de Datos · UTEC

Prof. Germain García-Zanabria | Equipo: Miguel · Alejandro · Diego · Christopher

Agenda de la presentación

1	El producto, el problema y el usuario	Qué es DreemGO y a quién sirve
2	Recomendaciones del profesor incorporadas	De reglas estáticas a analítica predictiva
3	Arquitectura de datos	Tres fuentes, un modelo relacional
4	Objetivos del EDA	Seis preguntas y su relación con el problema
5	Pre-procesamiento y justificación	Faltantes, llaves, outliers, transformaciones
6	Análisis descriptivo	Espacial, climático y comercial
7	Motor predictivo y hallazgos	Score de viabilidad y decisiones de producto
8	Retos, limitaciones y próximos pasos	Qué no podemos afirmar todavía

Resumen ejecutivo

6,160

fichas del inventario MINCETUR

20.2%

sin coordenadas: 1,245 fichas

2,880

meses de clima 2014–2023

95.8%

cruce clima logrado tras normalizar llaves

Tres conclusiones que cambian el plan de modelado

- La estacionalidad hídrica es la señal predictiva más fuerte del proyecto: la precipitación se concentra en diciembre–marzo y discrimina regiones mucho mejor que la temperatura.
- La calidad de los datos exige dos correcciones antes de modelar: 1,245 fichas sin geometría (20.2%) y llaves de región con acentos que rompían el cruce (recuperamos 19.4 puntos de cobertura).
- Dos variables del dataset actual no aportan información: TIPO_INGRESO es 100% derivable de JERARQUIA_OFICIAL, e INDICE_COSTO_LOGISTICO replica DISTANCIA_CAPITAL_KM ($\rho = 0.94$).

El problema y el usuario

La ecuación que hoy el viajero resuelve a mano

¿Qué ver?

Intereses y categorías turísticas dispersas en 6,160 fichas oficiales

¿Dónde es viable?

Altitud, clima y temporada: la geografía peruana inviabiliza rutas enteras

¿Cómo conectarlo?

Logística entre destinos sin red vial ni tiempos de traslado

CONSECUENCIA

Parálisis por análisis

El turista compara múltiples pestañas sin poder optimizar su ruta y termina concentrándose en los mismos tres destinos saturados.


El inventario público de MINCETUR existe, pero nadie lo convierte en una decisión.

Usuario primario: viajero nacional independiente con tiempo o presupuesto acotado.


POSICIONAMIENTO

DreemGO no es un buscador: es un optimizador de itinerarios que cruza intereses, viabilidad geográfica y temporada antes de proponer una ruta.

La app DreemGO: qué hace y cómo fluye



Modelo de negocio: mercado de dos lados (flywheel)



IMPLICANCIA PARA EL EDA

Cada paso del flujo depende de una tabla distinta: por eso el EDA se organiza en tres frentes (espacial, climático y comercial), no en uno solo.

Lo que recomendó el profesor y cómo lo resolvimos

Observación del profesor	Situación previa (Semana 5)	Cómo se aborda en la Semana 6
Época propicia como texto	Regla estática declarada en la ficha ("Abril a Noviembre")	Score continuo región × mes sobre 2,880 meses históricos
Sin dimensión temporal real	El mes de viaje no modificaba el resultado	Matriz de riesgo hídrico 24 regiones × 12 meses
Variables continuas crudas	Precipitación y temperatura entran tal cual al modelo	Discretización paramétrica justificada + variables categóricas
Sin analítica predictiva	Solo filtros descriptivos sobre el inventario	Motor de viabilidad + forecasting estacional (SEM 7)
Trazabilidad débil	Datos enriquecidos sin origen verificable	100% de los recursos conserva su URL oficial (RNF-01)

MENSAJE CLAVE

El cambio de fondo: pasar de reglas estáticas escritas a mano a señal estimada a partir de 10 años de datos meteorológicos observados.


03

Arquitectura de datos

Tres fuentes heterogéneas integradas en un modelo relacional con llave REGION

Arquitectura de datos: del origen al producto

Arquitectura de datos DreemGO · Semana 6



Trazabilidad: cada recurso conserva el enlace a su ficha oficial (URL) — RNF-01

Modelo relacional (data lake en /data/processed/)

Tabla	Rol	Filas	Origen	Llave
dreemgo_master_dataset.csv	Dimensión · Ubicaciones	6,160	MINCETUR + feature engineering	PK: CODIGO DEL RECURSO
historial_clima_regiones.csv	Hechos · Clima	2,880	Open-Meteo Archive 2014-2023	FK: REGION
comercios_ferias_locales.csv	Hechos · Eventos	500	Generador sintético de marketplace	FK: REGION

Las tres fuentes: qué contiene cada una

MINCETUR

Inventario Nacional de Recursos Turísticos

- 6,160 fichas oficiales, 25 regiones
- 19 variables tras el enriquecimiento
- Jerarquía oficial, categoría y URL
- 20.2% sin coordenadas

Open-Meteo

Archive API · serie histórica mensual

- 2,880 registros región × mes
- 24 regiones × 10 años × 12 meses
- Temperatura media y precipitación
- 0% de valores faltantes

Marketplace

Eventos y ferias locales (sintético)

- 500 eventos en 9 regiones
- 5 categorías comerciales
- Ventana de fechas y costo
- Relevancia publicitaria 1-5

NOTA DE INTEGRACIÓN

Las tres fuentes se cruzan por REGION, y solo el 9 de 25 regiones tiene eventos comerciales: la monetización está concentrada por diseño.

Objetivos del EDA: seis preguntas

P1 ¿Dónde se concentra la oferta turística?

Detecta el sesgo territorial que el producto debe corregir

P2 ¿La discretización de altitud es coherente?

Valida que ZONA_CLIMATICA sea una variable fiable

P3 ¿Qué variables son redundantes antes de modelar?

Evita multicolinealidad y sobreajuste en el clustering

P4 ¿Cuándo y dónde llueve? ¿Hay estacionalidad explotable?

Es el núcleo del motor predictivo recomendado por el profesor

P5 ¿La oferta comercial permite monetizar la ruta?

Mide la viabilidad del marketplace de dos lados


P6 ¿La calidad de datos soporta el modelo?

Documenta faltantes, duplicados y cobertura de cruces

CRITERIO DE CALIDAD

Cada pregunta se responde con una visualización y termina en una decisión de diseño del producto, no en una observación suelta.

Calidad de datos: el bloque de faltantes




DIAGNÓSTICO

Los 7,471 valores faltantes **NO** están dispersos: se concentran en un solo bloque de 1,245 fichas (20.2%) que nunca recibió enriquecimiento geoespacial.

Pre-procesamiento: qué hicimos y por qué

Situación encontrada	Evidencia	Decisión y justificación
Faltantes geoespaciales (1,245 fichas)	NaN en latitud, longitud, altitud, distancia y zona climática	No se imputan: se excluyen del cálculo de rutas y se conservan como capa de contexto por distrito
Llaves de región inconsistentes	"ÁNCASH" vs "ANCASH", "JUNÍN" vs "JUNIN" rompían el join	Normalización Unicode (NFKD) + mayúsculas + trim antes de cruzar
Tipos de datos	latitud y longitud llegan como texto desde el CSV	Coerción numérica con errors='coerce' y conteo explícito de fallos
Outliers de precipitación (74 casos, 2.6%)	Cola derecha extrema: máximo 765.8 mm mensuales	Se conservan: son eventos climáticos reales (Fenómeno de El Niño), no errores de captura
Duplicados	0 filas duplicadas y 0 códigos de recurso repetidos	Verificación de PK: no requiere deduplicación
Variable redundante	TIPO_INGRESO se derivaba de JERARQUIA_OFICIAL	Se marca para exclusión del modelo: aporta 0 información ($\chi^2 = 6160$, $p < 0.001$)

El bug de llaves que costaba 19 puntos de cobertura

**IMPACTO MEDIBLE**

Sin normalizar, solo 76.5% de los recursos cruzaba con clima. Normalizando llaves subimos a 95.8%: la única región realmente sin datos climáticos es Callao.


Feature engineering: las variables que creamos

Variable	Cómo se construyó	Tipo	Observación
ALTITUD	API Open-Meteo (elevación)	Continua	0 – 6,692 m s. n. m.
ZONA_CLIMATICA	Discretización de altitud en 7 pisos ecológicos	Nominal	rangos disjuntos → válida
DISTANCIA_CAPITAL_KM	Distancia Haversine al nodo logístico	Continua	media 74.4 km
INDICE_COSTO_LOGISTICO	Binning de la distancia en 3 niveles (1–3)	Ordinal	redundante con distancia ($p = .94$)
TIPO_INGRESO	Regla derivada de la jerarquía oficial	Binaria	derivable → excluir
JERARQUIA_OFICIAL	Enriquecimiento del inventario (1–4)	Ordinal	4 niveles
NIVEL_RIESGO_CLIMATICO	Discretización paramétrica de la precipitación	Ordinal	≤ 30 seguro · ≤ 100 precaución · > 100 peligro
SENSACION_TERMICA	Discretización de la temperatura media	Nominal	≤ 10 frío · ≤ 20 templado · > 20 cálido

PARA EL MODELO

Las dos últimas filas son la materia prima del motor predictivo: convierten 2,880 registros continuos en etiquetas que el recomendador puede cruzar en milisegundos.



Análisis espacial: dónde está la oferta



P1 · DISTRIBUCIÓN ESPACIAL

Los 4,915 recursos georreferenciados dibujan la geografía del país: la altitud separa costa, sierra y selva, y la zona climática resultante es coherente región por región.



Análisis espacial: altitud y pisos ecológicos



P2 · DISCRETIZACIÓN VÁLIDA

La mediana de altitud es 2,407 m y el 26.7% del inventario supera los 3,500 m: la altitud no es un detalle, es un criterio de exclusión para buena parte de los viajeros.

Oferta turística: qué se ofrece y dónde



P1 · SESGO TERRITORIAL


Sitios naturales y manifestaciones culturales concentran el 69% del inventario, pero Lima y Cusco acaparan el 23.1% de los recursos georreferenciados.

Hallazgo crítico: variables redundantes

Variable redundante: TIPO_INGRESO es derivable al 100% de JERARQUIA ($\chi^2=6160$, $p<0.001$)

JERARQUIA_OFICIAL	TIPO_INGRESO	
	Libre	Pagado
1	2,577	0
2	2,144	0
3	0	1,122
4	0	317



Correlaciones (Spearman) entre variables núcleo del recomendador



P3 · SELECCIÓN DE VARIABLES

Dos variables del dataset actual no aportan información independiente. Incluirlas en el clustering duplicaría el peso de la logística y sesgaría el modelo.




Análisis climático: la estacionalidad es la señal



P4 · SEÑAL PREDICTIVA

La precipitación se concentra entre diciembre y marzo (hasta 159.6 mm de media en marzo frente a 56.3 mm en mayo) y la selva llueve 6× más que la costa.



Análisis climático: asimetría y variables derivadas



P4 · TRATAMIENTO DE OUTLIERS

La precipitación tiene asimetría positiva (skew = 1.50) con 74 meses extremos. Esos extremos son justamente los que hacen inviable una ruta, así que se modelan, no se borran.




Análisis climático: temperatura y tendencia



P4 · DECISIÓN DE MODELADO

Temperatura y lluvia están prácticamente incorrelacionadas ($\rho = -0.03$) y no hay tendencia interanual: el modelo debe ser estacional, no de tendencia.


Análisis comercial: ¿se puede monetizar?



P5 · VIABILIDAD DEL MARKETPLACE

El 30.6% de los eventos es gratuito y la relevancia publicitaria es casi uniforme (media 3.01): el score actual no discrimina lo suficiente para priorizar anuncios.

Motor predictivo: score de viabilidad climática



RECOMENDACIÓN DEL PROFESOR, IMPLEMENTADA

El score cruza 24 regiones × 12 meses y sustituye la regla estática de “época propicia” por evidencia de 10 años: Loreto y Madre de Dios caen por debajo de 55 en verano.

Espacio reservado: notebook y datos del EDA

ENLACE AL NOTEBOOK DE COLAB Y LAS CAPTURAS DE SALIDA

- Enlace público del notebook Colab ejecutado (ver entrega del criterio 5).
- Captura de las celdas de salida: mapa de recursos, curva de estacionalidad y conteo por categoría.
- Este deck ya incluye los resultados del EDA calculados sobre la data de la rama Miguel (deliveries/week06). Estas dos diapositivas son para el material complementario del notebook.

Rutas reproducibles dentro del repositorio

Ruta	Qué hace	Salida
analysis/01_profile.py	Perfilado: tipos, nulos, cardinalidad, integridad referencial	profile.txt
analysis/02_eda.py	EDA completo y las 12 figuras del deck	out/fig/*.png
deck/build_deck.py	Generador de esta presentación (29 diapositivas)	este .pptx
deliveries/week06/code/	Scripts ETL y notebooks de la rama Miguel	3 tablas procesadas

Retos y limitaciones de los datos

Limitación	Evidencia en los datos	Impacto en el proyecto
Faltantes estructurales	20.2% del inventario (1,245 fichas) sin coordenadas ni altitud	Esas fichas no pueden entrar a ninguna ruta. El producto solo puede operar sobre el 79.8% del inventario oficial.
Extracción web ruidosa e Imputación	TIPO_INGRESO y EPOCA_PROPICIA se extrajeron con ruido HTML y tuvieron que ser sobrescritas mediante Reglas Lógicas (Imputación).	Se logró extraer el 100% de la JERARQUIA_OFICIAL real, pero el costo y época del recurso son inferencias matemáticas provisionales.(1.5–2 h con red).
Dataset comercial sintético	Los 500 eventos se generan aleatoriamente, sin fuente real	Permite validar la arquitectura, pero no sostiene ninguna afirmación de negocio.
Cobertura comercial parcial	Solo 9 de 25 regiones tienen eventos; 17 no tienen ninguno	El marketplace nace sesgado hacia las regiones ya populares, justo lo contrario del objetivo de descentralización.
Llave geográfica frágil	REGION es texto libre con acentos y mayúsculas inconsistentes	Cualquier fuente futura puede romper el join. Se necesita un código de región canónico.
Distancia geodésica	No hay red vial: la distancia Haversine subestima el tiempo real	El itinerario es optimista en zonas de sierra; OpenStreetMap entra en la Semana 10.

Cómo mitigamos cada limitación

Reescribir el Parser del Scraper

Programar un parser DOM específico para navegar el HTML antiguo de MINCETUR y reemplazar las variables imputadas (Costo y Época) por el dato crudo real.

Código canónico de región

Agregar un ID_REGION estable (INEI) y dejar REGION solo como etiqueta de presentación.

Reparar la geometría faltante

Geocodificar por distrito las 1,245 fichas sin coordenadas para recuperar el 20.2% perdido.

Fuente real de eventos

Reemplazar el generador sintético por scraping de ferias regionales con licencia redistribuible.

Red vial y tiempos reales

Integrar OSMnx / OpenStreetMap en la Semana 10 para tiempos de viaje creíbles.

Reconstruir el score comercial

Redefinir RELEVANCIA_PUBLICIDAD con señal real (clics o reservas) antes de usarlo como priorizador.

CONCLUSIÓN

Ninguna limitación bloquea el avance: todas tienen ruta de mitigación y fecha tentativa dentro del cronograma del curso.

De los hallazgos a las decisiones de producto

	Hallazgo del EDA	Decisión de producto
P1	Lima y Cusco concentran el 23.1% de la oferta	El recomendador debe penalizar explícitamente los destinos saturados
P2	La discretización por altitud es coherente (rangos disjuntos)	ZONA_CLIMATICA se mantiene como variable de filtrado del motor
P3	TIPO_INGRESO e INDICE_COSTO_LOGISTICO son redundantes	Excluir las del clustering para no duplicar el peso de la logística
P4	Estacionalidad marcada dic-mar; sin tendencia interanual	Modelo estacional con score región × mes, no serie con tendencia
P5	Relevancia publicitaria casi uniforme (media 3.01)	Rediseñar el score antes de usarlo para priorizar anuncios
P6	20.2% sin geometría y llaves frágiles	Geocodificar faltantes y adoptar un código canónico de región

Próximos pasos · Semana 7

- | | | |
|----|--|---|
| S1 | Entrenar el Recomendador Comercial (B2B) | Implementar Content-Based Filtering para inyectar eventos locales dinámicos en el itinerario. |
| S2 | Geocodificar el 20.2% faltante | Recuperar 1,245 fichas para el cálculo de rutas |
| S3 | Entrenar el Forecasting Climático | Aplicar Random Forest sobre la matriz histórica de 10 años para predecir el nivel de riesgo. |
| S4 | Entrenar el clustering de polos | K-Means / HDBSCAN ponderando distancia y clima (Silueta) |
| S5 | Integrar red vial con OSMnx | Sustituir la distancia geodésica por tiempos reales |
| S6 | Versionar el notebook del EDA | Publicar en Colab con salidas y enlazarlo a este deck |

ESTADO

El EDA deja el pipeline listo para modelar: datos limpios, variables seleccionadas y una variable objetivo validada.

DreemGO · Semana 6

EDA sobre 3 fuentes · 12 visualizaciones · 6 hallazgos accionables

- 6,160 fichas, 2,880 meses de clima y 500 eventos integrados en un modelo relacional.
- Se corrigieron 2 defectos de datos y se detectaron 2 variables redundantes antes de modelar.
- La estacionalidad hídrica queda validada como la señal predictiva central del producto.
- Limitaciones declaradas con evidencia y con ruta de mitigación agendada.

Equipo: Miguel · Alejandro · Diego · Christopher

DS3022 Desarrollo de Producto de Datos · UTEC · Prof. Germain Garcia-Zanabria
GitHub: <https://github.com/oswaldoaqm/Alejandros-Team.git>